



教育背景

上海科技大学 | 计算机科学与技术 · 本科

2025.09 - 至今

已修课程：操作系统 I、计算机安全 I、计算机编程、信息科学技术导论。

实习经历

浦江实验室 | 大模型评测实习生

2026.08 - 2026.09

AgentCompass | Agent 指令遵循评测

- 设计并向原任务 instruction.md 注入 against-prior 轨迹约束，基于 AgentCompass 与 TerminalBench 2.1 Verified 构建**任务完成度与执行过程合规性**联合评测。
- 实测 GLM-5.2 与实验室内部模型，依据约束通过差异筛选具有难度梯度与区分度的候选约束。
- 以可验证行为或状态描述约束，允许多种合规路径，避免验证器退化为固定命令序列匹配。
- 编写新增约束的**独立验证器 (verifier)**，结合执行轨迹、原任务测试与约束判定结果，形成可自动运行的 Agentic IF 验证流程。

Rubric Pipeline | 自动评分标准生成与实测

- 搭建从题目与显式约束**零起点生成 rubric**的分阶段流水线，覆盖题目准备、评分标准生成与诊断、回答实测、区分度分析及反馈修订。
- 冻结评分标准后再引入候选回答**，隔离生成输入与评测对象；按生成、诊断、判分与答案求解划分模型角色，并引入异源答案交叉复核。
- 结合多档回答实测与自动化测试迭代评分标准，导出 JSONL、XLSX 与运行清单，并保留交付审计记录，形成可追溯的交付产物。

精选项目

AI Airlock | AI Agent 本地上下文安全网关

2026.08

- 构建 AI Agent 本地上下文网关，先检测、变换与隔离敏感信息和提示注入，再以 OpenVINO 对净化证据排序，输出带来源定位、受预算约束的 Safe Context Capsule。
- 对比规则基线与 OpenVINO，平均 Recall@K 从 **0.583 提升至 0.938**；评测限于 rc.1 的 **12 个冻结合成相关性任务**，并同步记录延迟开销。
- 完成 rc.7 发布包的独立安装与 CLI 验证，**234 项测试通过、9 项跳过**，对应 Windows / Ubuntu CI 通过；验证范围不含真实 Agent 宿主端到端验收。

Octopus | 本地研究资料检索与证据工作台

2026

- 基于 SQLite FTS5 构建 Windows 本地资料检索工作台，支持 PDF、Office、图片与 ZIP 成员的全文检索、增量同步及页面、段落、表格或单元格级证据定位。
- 实现证据确认、来源变更后的重新核验与资料包导出，产物包含研究正文、BibTeX、任务快照及来源清单；原始资料保持只读。
- 获上海科技大学第二届 AI 智能创新应用大赛**优秀作品奖**。

精选项目（续）

DeepSeek Harness | 轨迹控制与工作区插件

2026.08

dsh-trajectory-control · trajectory-workspace-plugin

- 扩展 DeepSeek Harness 轨迹视图，支持从已完成交互轮次的中间事件**创建子会话并携带新指令续跑**，保留原始轨迹以便对照不同执行路径。
- 定位并修复未被插件认领的 replacement 事件空白渲染，补齐 Session.append 的 ignorable 写入字段，支持替换事件展示与可忽略事件写入。
- 开发可停靠、浮动、拖动及缩放的轨迹工作区插件，复用官方 TrajectoryView，按会话保存位置与尺寸；交付插件包及配套宿主集成补丁。

LLM Model Audit Toolkit | 行为指纹审计

2026.08 - 2026.09

llm-fingerprint-detector · llm-relay-auditor

- 基于已有单 token 行为分布比较方法开发 **TypeScript 库与 CLI**，并使用 FastAPI 构建批量审计工作台，完成参考指纹冻结、目标采样与 JSON / CSV 报告导出。
- 设置**三轮参考快照**，校验采样协议、样本质量与证据哈希，输出 Jensen-Shannon 散度（JSD）及 bootstrap 95% 区间，支持端点行为差异的追溯与比较。
- 在报告中区分采样质量、协议兼容性与分布差异，将比较结果限定为未校准的探索性证据，不把相似度解释为模型身份或供应商真实性。

Pintos | 操作系统课程项目

2026

- 在 Pintos x86 教学内核中实现优先级调度与**嵌套优先级捐赠**，沿锁依赖链传播优先级，并在释放锁时移除对应捐赠、重新计算有效优先级。
- 实现系统调用、用户指针校验及 exec/wait 父子进程同步，处理加载失败、退出状态传递与资源回收，明确用户态与内核态的访问边界。
- 实现按需分页、swap 与 mmap，结合 Clock 页面置换和物理页固定（frame pinning），协调缺页处理、页面驱逐与 I/O 并发。
- 实现多级索引可扩展文件、子目录及 **64 扇区块缓存**，支持后台回写与顺序预读；对扩容失败回滚新增磁盘块，处理文件增长中的一致性问题的。

专业技能

编程语言：Python、C/C++；TypeScript（项目实践）。

LLM / Agent：轨迹约束与验证器、跨模型评测、Rubric 生成与评分、上下文安全处理。

开发与验证：Linux、Git、pytest、Ruff、GitHub Actions；自动化测试与发布包验证。

框架与组件：FastAPI、SQLite FTS5、OpenVINO。

研究兴趣：Multimodal Agent、3D Vision / Generation。